# Deep Learning and Practice Lab 1 309552007

## 袁鈺勛

#### 1. Introduction

這次 lab 要實作 neural network ,利用 forward propagation 得到預測答案 ,將預測答案和真實答案之間的差距經過 backpropagation 回傳 ,藉此來更新 layer 的 weights,便可以使預測答案更接近真實答案。其中實作了 layer class 以及 neural network class , neural network class 會以 layer class 來建構 出 network,並且可以透過 command line arguments 來控制 neural network 的 optimizer、activation function 以及 learning rate 等,以此來觀察變更 neural network 的架構或參數會對學習過程以及準確度有什麼影響。

## 2. Experiment setups

## A. Sigmoid functions

```
@staticmethod
def sigmoid(x: np.ndarray) → np.ndarray:
    """

    Calculate sigmoid function
    y = 1 / (1 + e^(-x))
    :param x: input data
    :return: sigmoid results
    """

    return 1.0 / (1.0 + np.exp(-x))

@staticmethod
def derivative_sigmoid(y: np.ndarray) → np.ndarray:
    """

    Calculate the derivative of sigmoid function
    y' = y(1 - y)
    :param y: value of the sigmoid function
    :return: derivative sigmoid result
    """

    return np.multiply(y, 1.0 - y)
```

上圖為 sigmoid function 以及 derivative sigmoid function,他們被實作在 layer class 內,sigmoid function 用在 forward propagation,derivative sigmoid 則用於 backpropagation。

#### B. Neural network

上圖為 neural network class,具有 forward 和 train 等功能。

```
self.num_of_epoch = epoch
self.learning_rate = learning_rate
self.hidden_units = hidden_units
self.activation = activation
self.optimizer = optimizer
self.learning_epoch, self.learning_loss = list(), list()

# Setup layers
# Input layer
self.layers = [Layer(input_units, hidden_units, activation, optimizer, learning_rate)]

# Hidden layers
for _ in range(num_of_layers - 1):
    self.layers.append(Layer(hidden_units, hidden_units, activation, optimizer, learning_rate))

# Output layer
self.layers.append(Layer(hidden_units, 1, 'sigmoid', optimizer, learning_rate))
```

上圖為 neural network class 的 initial function,會在這個 function 利用 layer class 來建立 neural network。

```
class Layer:

def __init__(self, input_links: int, output_links: int, activation: str = 'sigmoid', optimizer: str = 'gd',

learning_rate: float = 0.1):...

def forward(self, inputs: np.ndarray) → np.ndarray:...

def backward(self, derivative_loss: np.ndarray) → np.ndarray:...

def update(self) → None:...

@staticmethod
def sigmoid(x: np.ndarray) → np.ndarray:...

@staticmethod
def derivative_sigmoid(y: np.ndarray) → np.ndarray:...

@staticmethod
def tanh(x: np.ndarray) → np.ndarray:...

@staticmethod
def derivative_tanh(y: np.ndarray) → np.ndarray:...
```

上圖為 layer class, 具有 forward 等功能, 還有 sigmoid 等 activation function。

#### C. Backpropagation

```
def backward(self, derivative_loss) → None:
    """
    Backward propagation
    :param derivative_loss: loss form next layer
    :return: None
    """
    for layer in self.layers[::-1]:
        derivative_loss = layer.backward(derivative_loss)
```

上圖為 neural network 的 backpropagation, 他會從 output layer 開始往 input layer 回推,並且將 loss 送給上一層。

```
def backward(self, derivative_loss: np.ndarray) \rightarray:
    """

    Backward propagation
    :param derivative_loss: loss from next layer
    :return: loss of this layer
    """

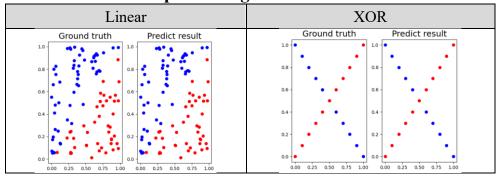
    if self.activation = 'sigmoid':
        self.backward_gradient = np.multiply(self.derivative_sigmoid(self.output), derivative_loss)
    elif self.activation = 'tanh':
        self.backward_gradient = np.multiply(self.derivative_tanh(self.output), derivative_loss)
    elif self.activation = 'relu':
        self.backward_gradient = np.multiply(self.derivative_relu(self.output), derivative_loss)
    elif self.activation = 'leaky_relu':
        self.backward_gradient = np.multiply(self.derivative_leaky_relu(self.output), derivative_loss)
    else:
        # Without activation function
        self.backward_gradient = derivative_loss

return np.matmul(self.backward_gradient, self.weight[:-1].T)
```

上圖為 layer 的 backpropagation,會根據所用的 activation function 算出 backward gradient 並且 return 這層的 loss。

## 3. Results of your testing

## A. Screenshot and comparison figure



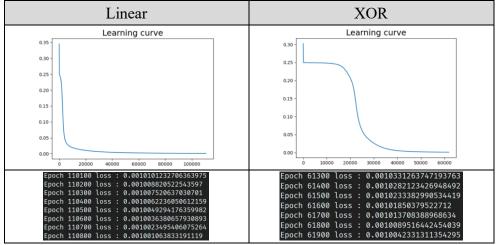
上面的圖表可以看出 network 都準確預測出答案。

## B. Show the accuracy of your prediction

| Linear            | XOR            |  |
|-------------------|----------------|--|
| [9.99998687e-01]  | [0.01167167]   |  |
| [9.99852269e-01]  | [0.99807562]   |  |
| [9.99998666e-01]  | [0.00692729]   |  |
| [9.57588355e-01]  | [0.99811201]   |  |
| [9.99656478e-01]  | [0.00479668]   |  |
| [9.99997914e-01]] | [0.99809027]]  |  |
| Accuracy : 1.0    | Accuracy : 1.0 |  |

由上表可以看出 network 對於 linear 這個比較簡單的問題會給出較接近 1 或 0 的機率。

## C. Learning curve

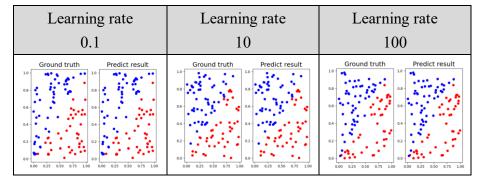


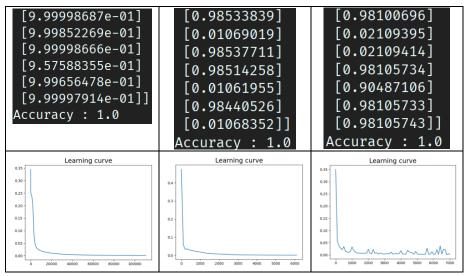
由上表可以看出在 linear 這個比較簡單的問題時不太會出現像 XOR 一樣在收斂前會在某處持續一段 epoch 都是差不多的 loss, 然後才開始往下降。

## 4. Discussion

## A. Try different learning rates

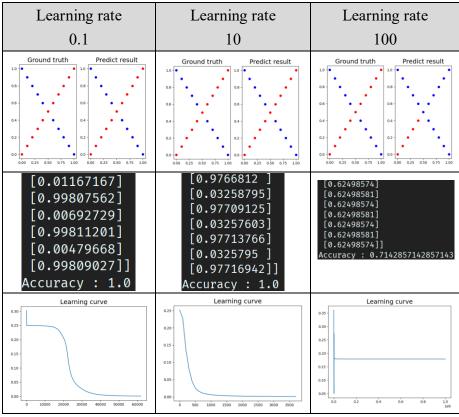
#### a. Linear





固定 hidden layer 有 4 個 units,由上表可以看出當 learning rate 太大的時候,learning curve 便會出現震盪。

#### b. XOR

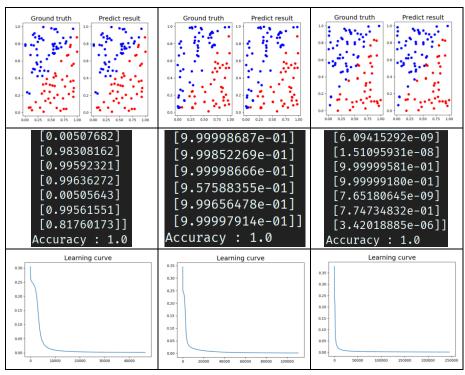


和 linear 一樣固定 units,同樣在 learning rate 太大的時候會出現震盪,甚至影響 accuracy。

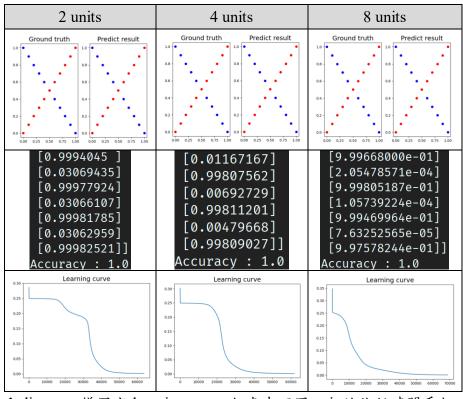
## B. Try different numbers of hidden units

#### a. Linear

| 2 units | 4 units | 8 units |
|---------|---------|---------|
|---------|---------|---------|



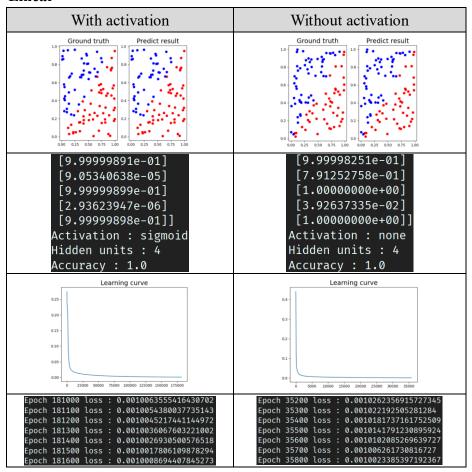
固定 learning rate 為 0.1,由上表可以看出由左至右當 unit 增加會造成較慢收斂,可能是因為 linear 是簡單的問題但用太多 unit 反而只是增加複雜度和 loss 總值而已。



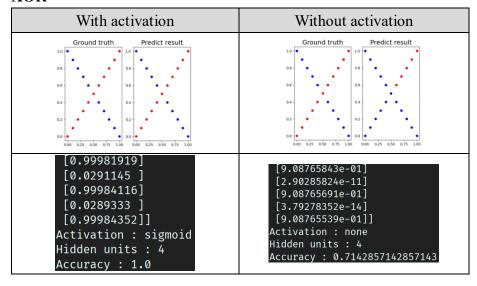
和 linear 一樣固定 learning rate,但表中不同 unit 的收斂時間看起來沒有太大的差異,可是當 unit 增加時,learning curve 變得較為平滑,呈現出 unit 較多時學習成效較好的結果。

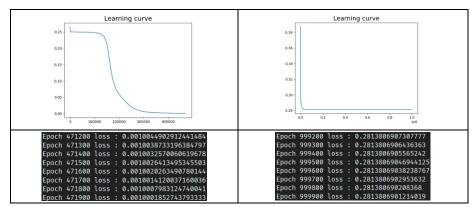
## C. Try without activation functions

#### a. Linear



固定 hidden layer 有 4 個 units 且 learning rate 為 0.1,由上表看不太出來 w/o activation function 對 accuracy 有沒有影響,但是 with activation 時會收斂較慢可能是因為 sigmoid 會將 output 限縮在 0至 1,且會有 vanishing gradient 作用。



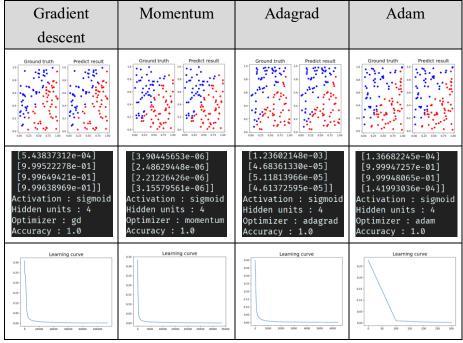


和 linear 一樣固定 4 個 units,但 learning rate 改為 0.01,由上表便可明顯看出 with activation 會收斂得比較快,without activation 反而要跑到 epoch 的上限才會停,同時 without activation 也對 accuracy 產生了影響。

#### 5. Extra

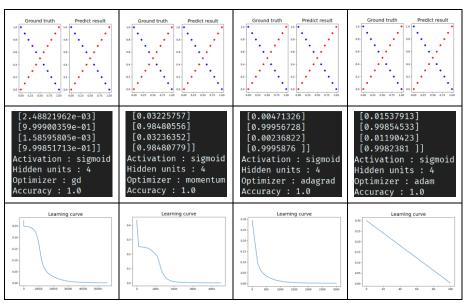
## A. Implement different optimizers

#### a. Linear



固定 hidden layer 是 4 個 units 且 learning rate 是 0.1,由上面的表格可以看出來由左至右收斂的速度愈快,因為除了 gradient descent 之外的 optimizer 會利用到 momentum 或是降低 learning rate 的方式來阻止震盪和加速收斂。

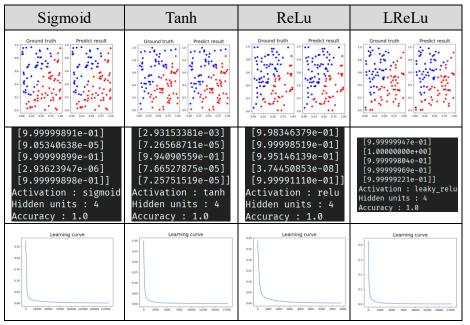
| Gradient | Momentum | Adagrad | Adam |
|----------|----------|---------|------|
| descent  |          |         |      |



由上表可以看出 XOR 的結果也和 linear 的一樣,同時 learning curve 看上去也由左至右更加平滑。

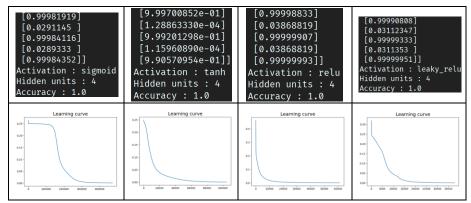
## B. Implement different activation functions

#### a. Linear



固定 hidden layer 有 4 個 units 且 learning rate 是 0.1,上面的結果 看不太出來各 activation 的差距,只有 ReLu 是比較快收斂而已。

| Sigmoid          | Tanh  | ReLu  | LReLu   |
|------------------|---|---|---|
| Ground truth  12 | Ground truth  Predict result  as  as  as  as  as  as  as  as  as  a | Ground truth  10  10  10  10  10  10  10  10  10  1 | Ground truth  Predict result  A B B B B B B B B B B B B B B B B B B |



和 linear 一樣固定 units 和 learning rate,但上表可以看出由左至右收斂的速度愈快,可能是 vanishing gradient 的影響。