

# Deep Learning and Practice Lab 7

309552007

袁鈺勛

## A. Introduction

這次 lab 是要實作 conditional GAN 和 conditional normalizing flow。在 cGAN 中，利用 condition 以及 latent code 讓 generator 產生 fake image，並利用 discriminator 來區分收到的 image 是否是真實的，藉此來訓練 generator 以及 discriminator。在 cNF 中，image 經由 flow 轉成 latent code，如果要生成 image 的話，會將 latent code 經由 inverse flow 來還原。

## B. Implementation details

### 1. GAN

在 gan 的選擇我是使用了最簡單的 dcgan，progressive growing of gan 是因為時間上所以沒有去考慮他，super resolution gan 是因為他的設計功能是將低解析度或模糊的照片輸入 generator 來產生高解析度的照片，所以不太適合這次的目的，sagan 則是有實作但不知道是不是哪裡實作錯誤導致效果不理想，所以沒有採納。在 condition 處理方面在 discriminator 裡面是將 label 經過 neural network 變成 1 channel 的 image 模樣的 condition，並且將他 concatenate 到 image 中當成第四個 channel，至於在 generator 裡面是在產生 noise 的時候就將他當成了 noise 的一部份讓 generator 產生 image。上述的方式便是下面兩張 code。

```

class DCGenerator(nn.Module):
    def __init__(self, noise_size: int, label_size: int): ...

    def forward(self, x: torch.Tensor) → torch.Tensor:
        """
        Generator forwarding
        :param x: Batched data
        :return: Batched image
        """
        return self.net(x)

class DCDiscriminator(nn.Module):
    def __init__(self, num_classes: int, image_size: int): ...

    def forward(self, x: torch.Tensor, label: torch.Tensor) → torch.Tensor:
        """
        Discriminator forwarding
        :param x: Batched data
        :param label: Batched labels
        :return: Discrimination results
        """
        batch_size, num_classes = label.size()
        label = label.view(batch_size, num_classes, 1, 1)
        condition = self.label_to_condition(label).view(batch_size, 1, -1)
        condition = self.linear(condition).view(-1, 1, self.image_size, self.image_size)
        inputs = torch.cat([x, condition], 1)
        return self.net(inputs).view(-1, 1)

```

## 2. NF

在 normalizing flow 的選擇我是使用了 glow，考量到 glow 的效果比 realnvp 好，不使用效果比 glow 好的 flow++ 是因為 flow++ 用到了 variational dequantization，所以他的架構上就像是有兩個 glow，在工作站的顯卡記憶體沒那麼大，連 glow 都不能用到常見的大小和深度，所以只有採用 glow，但在 preprocess 是採用 realnvp 的 logits 方式而不是 glow 原先的單純加 uniform noise。在 condition 處理方面是將 label 經過 neural network 轉成 1 channel 的 image 模樣的 condition，當成參數和 image 一起往 glow 裡面計算。

```

class ActNorm(nn.Module):
    """
    Activation normalization for 2D inputs.
    The bias and scale get initialized using the mean and variance of the first mini-batch.
    After the init, bias and scale are trainable parameters.
    Adapted from: https://github.com/openai/glow
    :arg in_channels: Number of channels in the input
    :arg scale: Scale factor for initial logs
    """

    def __init__(self, in_channels: int, scale: float = 1.): ...

    def initialize_parameters(self, x: torch.Tensor) → None: ...

    def _center(self, x: torch.Tensor, reverse: bool = False) → torch.Tensor: ...

    def _scale(self, x: torch.Tensor, sld: torch.Tensor, reverse: bool = False) → Tuple[torch.Tensor, ...]

    def forward(self, x: torch.Tensor, sld: torch.Tensor = None, reverse: bool = False) → Tuple[torch.Tensor, ...]

```

```

class InvConv(nn.Module):
    """
    Invertible 1x1 Convolution for 2D inputs.
    Originally described in Glow (https://arxiv.org/abs/1807.03039).
    :arg num_channels: Number of channels in the input and output
    """

    def __init__(self, num_channels: int): ...

    def forward(self, x: torch.Tensor, sld: torch.tensor, reverse: bool = False) → Tuple[torch.Tensor, ...]

```

```

class Coupling(nn.Module):
    """
    Affine coupling layer
    :arg in_channels: Number of channels in the input
    :arg mid_channels: Number of channels in the intermediate activation in NN
    """

    def __init__(self, in_channels: int, cond_channels: int, mid_channels: int): ...

    def forward(self,
                x: torch.Tensor,
                x_cond: torch.Tensor,
                sld: torch.Tensor,
                reverse: bool = False) → Tuple[torch.Tensor, ...]: ...

```

上面三張圖是 glow 的基本架構，分別是 ActNorm、Invertible 1x1 Convolution 和 Affine Coupling。

```

class NN(nn.Module):
    """
    Small convolutional network used to compute scale and translate factors.
    :arg in_channels: Number of channels in the input
    :arg cond_channels: Number of channels in the condition
    :arg mid_channels: Number of channels in the hidden activations
    :arg out_channels: Number of channels in the output
    """

    def __init__(self, in_channels: int, cond_channels: int, mid_channels: int, out_channels: int): ...

    def forward(self, x: torch.Tensor, x_cond: torch.Tensor) → torch.Tensor: ...

```

上圖中的 neural network 是用在 affine coupling 裡面，藉由 condition 和一半 channel 的 image 產生 scale 和 translate。

```

class FlowStep(nn.Module):
    """
    Single flow step
    Forward: ActNorm → InvConv → Coupling
    Reverse: Coupling → InvConv → ActNorm
    :arg in_channels: Number of channels in the input
    :arg cond_channels: Number of channels in the condition
    :arg mid_channels: Number of hidden channels in the coupling layer
    """

    def __init__(self, in_channels: int, cond_channels: int, mid_channels: int): ...

    def forward(self,
                x: torch.Tensor,
                x_cond: torch.Tensor,
                sld: torch.Tensor = None,
                reverse: bool = False) → Tuple[torch.Tensor, ...]: ...

```

上圖中便是 glow 中的一個 flow step，會經過上面提到的三個基本架構。

```

class CGlow(nn.Module):
    """
    Conditional Glow model
    :arg num_channels: Number of channels in the hidden layers
    :arg num_levels: Number of levels in the model (number of _CGlow classes)
    :arg num_steps: Number of flow steps in each level
    :arg num_classes: Number of classes in the condition
    :arg image_size: Image size
    """

    def __init__(self, num_channels: int, num_levels: int, num_steps: int, num_classes: int, image_size:
    ...): ...

    def forward(self,
                x_label: torch.Tensor,
                x: torch.Tensor = None,
                reverse: bool = False) → Optional[Tuple[torch.Tensor, ...] or torch.Tensor]: ...

    def get_mean_and_logs(self, data: torch.Tensor, label: torch.Tensor) → Tuple[torch.Tensor, ...]: ...

    def _pre_process(self, x: torch.Tensor) → Tuple[torch.Tensor, ...]: ...

```

最後會用這個 cGlow class 來遞迴式的建立每一層的多個 flow steps，

同時也是在這將拿到的 label 轉成 condition 的。

### 3. Hyperparameter


Argument	Description	Default
'-b', '--batch_size'	Batch size	64
'-i', '--image_size'	Image size	64
'-w', '--width'	Dimension of the hidden layers in normalizing flow	128
'-d', '--depth'	Depth of the normalizing flow	8
'-n', '--num_levels'	Number of levels in normalizing flow	3
'-gv', '--grad_value_clip'	Clip gradients at specific value	0
'-gn', '--grad_norm_clip'	Clip gradients' norm at specific value	0
'-lrd', '--learning_rate_discriminator'	Learning rate of discriminator	0.0002
'-lrg', '--learning_rate_generator'	Learning rate of generator	0.0002
'-lrnf', '--learning_rate_normalizing_flow'	Learning rate of normalizing flow	0.0005
'-e', '--epochs'	Number of epochs	300
'-wu', '--warmup'	Number of warmup epochs	10
'-t', '--task'	Task 1 or task 2	1 (1-2)
'-m', '--model'	cGAN or cNF	'dcgan'
'-inf', '--inference'	Only infer or not	False
'-v', '--verbosity'	Verbosity level	0 (0-2)

上圖為 hyperparameter 的設定，可以透過 argument 來調整。

## C. Results and discussion

### 1. Task 1

#### a. cGAN




Average accuracy: 0.47  
New Average accuracy: 0.51

上兩張圖分別是用 dcgan 產生的 test image 以及 test 和 new test 的 accuracy。相較於 normalizing flow 他的 latent code 的維度是比

image 還小的，所以他沒辦法如同 normalizing flow 有一對一關係，所以經由 latent code 產生的圖片有可能會 map 到別張，所以 accuracy 上下浮動比較大，但也因此他的 model 比 normalizing flow 小，也比較快收斂。

**b. cNF**



Average accuracy: 0.19  
New Average accuracy: 0.19

上兩張圖分別是用 glow 產生的 test image 以及 test 和 new test 的 accuracy。Normalizing flow 的好處是他設定了 latent code 和 image 各自所在的空間維度是一樣大的，所以他可以保持一對一，讓產生的圖片更精準，但我上面的圖和 accuracy 都不太理想，可能是因為顯卡的記憶體不夠讓 glow 塞下夠大的 model，或是因為我只有跑 200 epochs，可能跑得不夠久。

## 2. Task 2

以下的實驗成果是用預設超參數的 glow，只有跑 250 epochs。

**a. Conditional face generation**



上圖的做法是從 training data 中挑出 32 個 label，將 label 丟入 glow 中做 inverse flow 產生的 fake images，就是下圖的 code。但



fake images 看起來成效不是很好，有可能是 glow 的超參數設太小或是訓練的不夠久

```
# Get labels for inference
labels = torch.rand(0, num_classes)
for idx in range(32):
    _, label = train_dataset[idx]
    labels = torch.cat([labels, torch.from_numpy(label).view(1, 40)], 0)
labels = labels.to(training_device).type(torch.float)

# Produce fake images
with torch.no_grad():
    fake_images, _, _ = normalizing_flow.forward(x=None, x_label=labels, reverse=True)
```

## b. Linear interpolation



上圖的做法是從 training data 中選出 10 張照片，把他們兩兩經過 glow 得到各自的 latent code 後，得到 latent code 的 interval 和 label 的 interval，藉此便可以將新的 latent code 和 label 給 glow 做 inverse flow 得到 interpolation，就是下面的 code。可以看到 interpolation 在靠近中間的地方的 image 大多不是很清晰，原因應該就是在 face generation 提到的。

```
# Generate latent code
with torch.no_grad():
    first_z, _, _ = normalizing_flow.forward(x=first_image, x_label=first_label)
    second_z, _, _ = normalizing_flow.forward(x=second_image, x_label=second_label)

# Compute interval
interval_z = (second_z - first_z) / 8.0
interval_label = (second_label - first_label) / 8.0

# Generate linear images
for num_of_intervals in range(9):
    with torch.no_grad():
        image, _, _ = normalizing_flow.forward(x=first_z + num_of_intervals * interval_z,
                                                x_label=first_label + num_of_intervals * interval_label,
                                                reverse=True)
    linear_images = torch.cat([linear_images,
                               image.cpu().detach().view(1, 3, args.image_size, args.image_size)], 0)
```

## c. Attribute manipulation



上圖的做法是先從 training data 中取得一個 image，將他經過 glow 取得 latent，並取得 negative label 和 positive label 之間的 interval，再來是將所有的 image 經過 glow 取得 latent，並且將目標 attribute 是 positive 和 negative 的分別做平均並且得到他們的 interval，以這個 interval\_z 和 image latent 以及 label 的 interval 便可以經過 glow 做 reverse flow 得到 images，就是下面的 code。上面圖中的第一個 row 是做 smiling，第二個 row 是做 bald，可以看到幾乎沒有什麼變化，原因應該就是在 face generation 中提到的。

```
with torch.no_grad():
    latent, _, _ = normalizing_flow.forward(x=image, x_label=label)

# Get negative labels
neg_smiling_label = torch.clone(label)
neg_bald_label = torch.clone(label)
neg_smiling_label[0, 31] = -1.
neg_bald_label[0, 4] = -1.

# Get positive labels
pos_smiling_label = torch.clone(label)
pos_bald_label = torch.clone(label)
pos_smiling_label[0, 31] = 1.
pos_bald_label[0, 4] = 1.

# Compute conditional interval
interval_smiling_label = (pos_smiling_label - neg_smiling_label) / 4.0
interval_bald_label = (pos_bald_label - neg_bald_label) / 4.0

pos_z_mean = torch.zeros(*(latent.size()), dtype=torch.float)
neg_z_mean = torch.zeros(*(latent.size()), dtype=torch.float)
num_pos, num_neg = 0, 0
for images, labels in data_loader:
    images = images.to(training_device)
    labels = labels.to(training_device).type(torch.float)
    pos_indices = (labels[:, idx] == 1).nonzero(as_tuple=True)[0]
    neg_indices = (labels[:, idx] == -1).nonzero(as_tuple=True)[0]

    with torch.no_grad():
        z, _, _ = normalizing_flow.forward(x=images, x_label=labels)
        z = z.cpu().detach()

    if len(pos_indices) > 0:
        num_pos += len(pos_indices)
        pos_z_mean = (num_pos - len(pos_indices)) / num_pos * pos_z_mean + z[pos_indices].sum(dim=0)
    if len(neg_indices) > 0:
        num_neg += len(neg_indices)
        neg_z_mean = (num_neg - len(neg_indices)) / num_neg * neg_z_mean + z[neg_indices].sum(dim=0)
interval_z = 1.6 * (pos_z_mean - neg_z_mean)
interval_z = interval_z.to(training_device)
```



```
alphas = [-1.0, -0.5, 0.0, 0.5, 1.0]
for num_of_intervals, alpha in enumerate(alphas):
    with torch.no_grad():
        image, _, _ = normalizing_flow.forward(x=latent + alpha * interval_z,
                                                x_label=neg_label + num_of_intervals * interval_label,
                                                reverse=True)
    manipulated_images = torch.cat([manipulated_images,
                                    image.cpu().detach().view(1, 3, args.image_size, args.image_size)]),
```